PROJETO INTEGRADOR — BOLSA FUTURO DIGITAL

Desafio Técnico 1

Motores Preditivos e Dados — ETL, Limpeza e Enriquecimento de Dados

Contexto

A Distribuidora Vetor é uma atacadista B2B fictícia que vende para varejistas por meio de uma equipe comercial em campo. Como toda distribuidora com histórico de anos de operação, sua base de clientes acumulou dados cadastrais preenchidos por pessoas diferentes, em momentos diferentes, sem padronização — o que hoje compromete a qualidade de qualquer análise agregada (relatórios regionais, agrupamentos por bairro, segmentações comerciais).

Este desafio simula exatamente esse tipo de problema: dados reais de negócio raramente chegam limpos, e uma parte relevante do trabalho de um engenheiro de dados é decidir como tratar a ambiguidade — não apenas escrever código.

Objetivo do desafio

Construir um pipeline de ETL que receba a base de clientes da Distribuidora Vetor (fictícia, fornecida em anexo), identifique inconsistências e produza uma base final limpa e enriquecida, pronta para uso em relatórios agregados — com todas as decisões de tratamento documentadas e justificadas.

Situação-problema

O dataset fornecido contém, entre outras inconsistências, variações de escrita para o mesmo bairro. Exemplos reais desse tipo de problema:

- "Águas Claras", "Aguas claras", "AGUAS CLARAS" — mesma localidade, grafias diferentes
- "Norte (Águas Claras)" — uma subdivisão informal, sem correspondência oficial garantida
- Campos de telefone, CNPJ e data em formatos inconsistentes entre registros
- CEPs ausentes, inválidos ou não correspondentes ao bairro informado em texto livre

Sem tratamento, esse tipo de variação polui qualquer relatório agrupado por região — o mesmo bairro aparece como várias linhas distintas, diluindo a análise.

Escopo esperado / entregáveis

- Pipeline de ETL (Python) com etapas claras de extração, transformação e carga
- Base final tratada, persistida em banco SQL
- Tabela ou log de auditoria: valor original → valor tratado → critério/fonte da decisão
- Testes automatizados da lógica de normalização (chamadas externas devem ser simuladas nos testes, não reais)
- Documentação técnica explicando as regras adotadas e seus limites conhecidos
- Relatório curto (1-2 páginas) com os trade-offs da abordagem escolhida — o que decidiram automatizar, o que decidiram tratar manualmente, e por quê

Abordagens possíveis a considerar

As sugestões abaixo são pontos de partida, não um roteiro obrigatório. A equipe deve avaliar, escolher e justificar sua própria abordagem — inclusive combinando, descartando ou substituindo itens desta lista.

- Normalização textual determinística (caixa, acentuação, espaços, conteúdo entre parênteses)
- Dicionário de correspondência (variante → nome canônico), construído e ampliado ao longo do processo
- Enriquecimento via API pública gratuita de CEP (ex.: ViaCEP, BrasilAPI) como fonte de referência geográfica, com cache local dos resultados
- Critério explícito para lidar com divergências entre o bairro informado pelo cliente e o retornado pela consulta de CEP
- Tratamento de campos adicionais sujos (telefone, CNPJ, datas), a critério da equipe

Recursos de apoio disponibilizados

- Dataset fictício de clientes da Distribuidora Vetor, com inconsistências propositalmente inseridas
- Ambiente com acesso à internet liberado, para eventual consumo de APIs públicas
- Ambiente de banco de dados (PostgreSQL local) para persistência
- Rubrica de avaliação (documento à parte)

Restrições

- Não há acesso a dados ou sistemas reais da Primora — todo o cenário é fictício e autocontido
- Qualquer regra de negócio necessária ao desafio deve ser assumida e documentada pela própria equipe, não inferida de fontes externas à Primora